

Sugestões de resolução de incidentes através do uso de LLM's

João Sousa

**Dissertação para obtenção do Grau de Mestre em
Engenharia Informática, Área de Especialização em
Engenharia de Software**

**Orientador: Paulo Gandra Sousa
Supervisor: João Peixoto**

Declaração de Integridade

Declaro ter conduzido este trabalho académico com integridade.

Não plagiei ou apliquei qualquer forma de uso indevido de informações ou falsificação de resultados ao longo do processo que levou à sua elaboração.

Portanto, o trabalho apresentado neste documento é original e de minha autoria, não tendo sido utilizado anteriormente para nenhum outro fim.

Declaro ainda que tenho pleno conhecimento do Código de Conduta Ética do P.PORTO.

ISEP, Porto, 7 de janeiro de 2026

Resumo

The abstract should usually not exceed 200 words, or one page. When the work is written in Portuguese, it should have an abstract in English.

Palavras-chave: Modelo de Linguagem de Grande Escala, Inteligência Artificial, Processamento da Linguagem Natural, Incidente, Mitigação, Sugestão

Abstract

Se o trabalho estiver escrito em Português, este resumo deveria ser em língua Inglesa, com cerca de 200 palavras, ou uma página.

Keywords: Large Language Model, Artificial Intelligence, Natural Language Processing, Incident, Mitigation, Suggestion

Agradecimentos

Gostaria primeiramente de agradecer ao meu orientador de estágio, o Doutor Paulo Gandra Sousa, professor coordenador do Instituto Superior de Engenharia do Porto, pela sua constante disponibilidade, apoio e conselhos que tornaram o projeto muito mais enriquecedor.

Um agradecimento também ao supervisor da empresa João Peixoto, o melhor (e único) *Chief Technical Titan* que tive, não só pela confiança depositada em mim, mas também pelo acompanhamento e suporte prestado ao longo do meu percurso profissional na empresa.

Um obrigado em especial a todos os professores que me acompanharam, por todo o esforço que tiveram em transmitir os seus conhecimentos, tornando possível a realização dos meus objetivos profissionais e académicos, e ao ISEP por disponibilizar a estrutura para tudo isso poder acontecer.

Fica também um forte agradecimento ao meu colega universitário, João Brito, pelo companheirismo e disponibilidade para que, juntos, superássemos os mais variados obstáculos encontrados pelo caminho até este momento.

Agradecer especialmente à minha namorada, que me apoiou desde a minha entrada na vida universitária, pelos conselhos dados e pelos domingos bem passados a estudar, fazer projetos e a redigir este documento.

Por fim, a todos os meus colegas, amigos e família que sempre prestaram um enorme apoio, o meu imenso obrigado.

Conteúdo

Lista de Figuras	xiii
Lista de Tabelas	xv
Lista de Código	xvii
Lista de Acrónimos	xix
1 Introdução	1
1.1 Organização e Contexto	1
1.2 Problema	1
1.3 Objetivos	2
1.4 Planeamento	2
1.5 Considerações Éticas	3
1.6 Estrutura do Documento	4
2 Estado da Arte	5
2.1 Metodologia de Investigação	5
2.1.1 Pergunta(s) de Investigação	5
2.1.2 Metodologia PICOC(T)	5
2.1.3 Palavras-Chave	6
2.1.4 Critérios de Inclusão e Exclusão	7
2.1.5 PRISMA	8
2.2 Revisão de Literatura	9
2.2.1 Análise de Causa Raiz e Correlação de Incidentes	10
2.2.2 Sugestões de Mitigação e Uso de Incidentes Anteriores	10
2.2.3 Apoio à Contextualização de Incidentes com <i>LLMs</i>	11
2.3 Conclusão	12
3 Futuros Desenvolvimentos	13
3.1 Metodologia Proposta	13
3.2 Desenho da Solução	13
3.3 Fluxo de Funcionamento	15
3.4 Pressupostos e Restrições	16
3.4.1 Pressupostos	17
3.4.2 Restrições	17
Bibliografia	19

Lista de Figuras

1.1	WBS Detalhado	3
1.2	Diagrama de <i>Gantt</i>	3
2.1	Diagrama <i>PRISMA</i>	9
3.1	Diagrama de Implantação	14
3.2	Diagrama de Atividade	16

Lista de Tabelas

2.1	Metodologia PICOCT	6
2.2	Repositórios de Pesquisa	7
2.3	Critérios de Inclusão	8
2.4	Critérios de Exclusão	8
3.1	Pressupostos do Projeto	17

Lista de Código

2.1	Termos de Pesquisa	7
-----	------------------------------	---

Lista de Acrónimos

<i>ACM</i>	<i>Association for Computing Machinery.</i>
<i>ASE</i>	<i>Automated Software Engineering.</i>
<i>BMW</i>	<i>Bayerische Motoren Werke.</i>
<i>CTW</i>	<i>Critical Techworks.</i>
<i>FSE</i>	<i>ACM International Conference on the Foundations of Software Engineering.</i>
<i>ICSE</i>	<i>International Conference on Software Engineering.</i>
<i>LLM</i>	<i>Large Language Model.</i>
<i>NSPE</i>	<i>National Society of Professional Engineers.</i>
<i>OCEs</i>	<i>On-Call Engineers.</i>
<i>PRISMA</i>	<i>Preferred Reporting Items for Systematic reviews and Meta-Analyses.</i>
<i>RQ</i>	<i>Research Question.</i>
<i>SMS</i>	<i>Systematic Mapping Study.</i>
<i>TSG</i>	<i>Troubleshooting Guide.</i>
<i>TTM</i>	<i>Time to mitigate.</i>
<i>WBS</i>	<i>Work Breakdown Structure.</i>
<i>IA</i>	<i>Inteligência Artificial.</i>
<i>IPP</i>	<i>Instituto Politécnico do Porto.</i>
<i>ISEP</i>	<i>Instituto Superior de Engenharia do Porto.</i>
<i>PICOCT</i>	<i>População, Intervenção, Comparação, Outcome, Contexto e Tipo de estudo.</i>
<i>PLN</i>	<i>Processamento de Linguagem Natural.</i>
<i>PREPD</i>	<i>Preparação para Dissertação.</i>
<i>TI</i>	<i>Tecnologias de Informação.</i>
<i>TMR</i>	<i>Tempo Médio de Resposta.</i>

Capítulo 1

Introdução

Este capítulo apresenta a organização responsável pela ideia do tema a ser desenvolvido, o contexto do seu surgimento e os problemas que a originaram. São abordados os objetivos, o planeamento e as considerações éticas tidas em conta para executar a proposta. Por último, é descrita a estrutura deste documento de forma a facilitar a leitura do mesmo.

1.1 Organização e Contexto

A *Critical Techworks (CTW)* nasceu de um empreendimento conjunto entre a *Critical Software* e o grupo *Bayerische Motoren Werke (BMW)*. Estabelecida em 2018, esta empresa desenvolve *software* exclusivamente para os produtos da *BMW*. A sua missão é "transformar a forma como o mundo se move" focando-se para isso na transformação digital com as melhores práticas do mercado.

A organização estrutura-se em equipas ágeis multidisciplinares, agrupadas em unidades e domínios tecnológicos, o que promove autonomia, ciclos de desenvolvimento rápidos e colaboração contínua. Esta abordagem permite alinhar o desenvolvimento de *software* com necessidades reais dos veículos e serviços digitais da *BMW*.

O presente relatório foi desenvolvido no âmbito da unidade curricular de Preparação para Dissertação (PREPD) do Instituto Superior de Engenharia do Porto (ISEP), com o intuito de demonstrar o estudo de viabilidade de uma solução para o problema em causa.

1.2 Problema

Colocar prints do ITSM (ticket manual e automático) A análise e resolução de incidentes está no dia a dia das equipas que lidam com projetos potencialmente **críticos**. Um incidente é um **evento** que provoca **interrupção** ou **degradação** num qualquer serviço, e podem **comprometer** significativamente a disponibilidade dos serviços e resultar em perdas financeiras substanciais (J. Jiang et al. 2020). Estes incidentes podem ter por origem duas principais fontes: **automático**, através de métricas definidas pelas equipas; e **manuals**, criados por clientes das aplicações desenvolvidas. Um **registo de incidente (ticket)** é um documento, normalmente gerido por um sistema externo (como *ServiceNow* ou *Jira Service Management*), onde é possível visualizar detalhes do incidente, tais como a sua descrição e prioridade, e onde um elemento da equipa pode descrever os passos de resolução efetuados.

Na área de Tecnologias de Informação (TI), as equipas podem manter vários serviços em simultâneo e por essa razão os membros da equipa de suporte (responsáveis por manter os serviços estáveis **24x7**) podem ficar **sobrecarregados** de incidentes, fazendo com que

tenham de lidar com eventos provenientes de vários serviços paralelamente. Numa situação como esta, os membros da equipa de suporte podem ter um sentimento de **confusão**, misturando temas e errando nas suas análises, o que pode causar piores resoluções de incidentes e o aumento do tempo para mitigação (*Time to mitigate (TTM)*). Outro cenário frequente para os *On-Call Engineers (OCEs)* envolve incidentes que ocorrem fora do horário de expediente, especialmente durante a madrugada, quando o membro da equipa de suporte pode não estar na sua plena capacidade de raciocínio e operacional.

Foi também referido anteriormente os incidente com origem manual. Estes, são criados por clientes finais e/ou equipas de testes e podem conter mais ou menos informação. Muitas vezes, os *OCEs* necessitam de realizar uma **análise mais extensa** para compreender o conteúdo do incidente e a resolução mais eficaz a aplicar.

Uma interpretação ou resolução inadequada das ocorrências pode **reduzir a disponibilidade** dos serviços, o que, por sua vez, pode gerar **prejuízos significativos** para a organização, seja pela perda de receitas, seja pelo impacto negativo na experiência do utilizador final.

1.3 Objetivos

O objetivo desta investigação passa por realizar uma revisão de literatura sobre o problema em questão, a fim de perceber que ferramentas existem atualmente para solucionar o problema mencionado anteriormente. Dessa forma, entender se as ferramentas foram eficazes nos seus contextos e concluir se é possível desenvolver uma solução que preencha todos os requisitos necessários para satisfazer todas as partes interessadas.

No final, o propósito principal consiste em perceber se existe viabilidade para o desenvolvimento de uma solução capaz de:

- Gerar resumos de um incidente específico, com base na sua descrição e no histórico de incidentes semelhantes.
- Gerar sugestões de mitigação com base no histórico de incidentes semelhantes.
- Analisar registos das aplicações para melhorar resumos e sugestões.

Espera-se que, com a geração de textos em linguagem natural, se consiga uma resposta mais rápida e consistente, o que se reflete numa redução do Tempo Médio de Resposta (TMR) aos incidentes. Assim, a carga de trabalho associada a operações por parte dos membros da equipa de suporte envolvidos diminui, libertando-os para o desenvolvimento de novas funcionalidades. De igual forma, é esperado que a diminuição do TMR possa aumentar a disponibilidade das aplicações, o que traz um impacto direto ao cliente final. Adicionalmente, a utilização de informação histórica e, de forma opcional, de registos das aplicações, procura ir ao encontro dos requisitos das diferentes partes interessadas, apoiando a tomada de decisão e permitindo que as equipas dediquem mais tempo a outras atividades de valor.

1.4 Planeamento

O planeamento do trabalho foi definido com base numa *Work Breakdown Structure (WBS)*, que serviu de base à construção do diagrama de *Gantt* (Figura 1.1 e 1.2). A *WBS* permite estruturar o projeto em três fases distintas, cada uma com as respetivas tarefas e entregáveis.

Por sua vez, o diagrama de *Gantt* é utilizado para calendarizar as atividades, identificar dependências entre tarefas e definir marcos de controlo.

	WBS	Nome	Nível WBS	Duração	Início	Fim
1	1	Projeto Dissertação	Projeto	184 dias	01/10/25...	15/06/26...
2	1.1	Planeamento	Fase	11 dias	01/10/25...	15/10/25...
3	1.1.1	Formalização do Planeamento	Entregável	11 dias	01/10/25, ...	15/10/25, ...
4	1.2	Preparação	Fase	60 dias	16/10/25...	07/01/26...
5	1.2.1	Project Charter	Entregável	11 dias	16/10/25, ...	30/10/25, ...
6	1.2.2	Extended Abstract	Entregável	32 dias	31/10/25, ...	15/12/25, ...
7	-----	Primeira Entrega	Milestone	0 dias	15/12/25, ...	15/12/25, ...
8	1.2.3	Documento Final da Prepação	Entregável	17 dias	16/12/25, ...	07/01/26, ...
9	1.2.4	Apresentação	Entregável	17 dias	16/12/25, ...	07/01/26, ...
10	-----	Segunda Entrega	Milestone	0 dias	07/01/26, ...	07/01/26, ...
11	1.3	Desenvolvimento	Fase	113 dias	08/01/26...	15/06/26...
12	1.3.1	Protótipo da Solução	Entregável	92 dias	08/01/26, ...	15/05/26, ...
13	1.3.2	Documento Final	Entregável	113 dias	08/01/26, ...	15/06/26, ...
14	1.3.3	Apresentação Final	Entregável	21 dias	18/05/26, ...	15/06/26, ...
15	-----	Última Entrega	Milestone	0 dias	15/06/26, ...	15/06/26, ...

Figura 1.1: WBS Detalhado




Figura 1.2: Diagrama de *Gantt*

Este planeamento assegura a ligação entre os objetivos do projeto, os entregáveis previstos e o respetivo calendário, facilitando o acompanhamento do progresso ao longo de todo o seu desenvolvimento.

1.5 Considerações Éticas

Neste projeto, foram seguidos os princípios do Código de Ética e Conduta Profissional da *Association for Computing Machinery (ACM)*, do Código de Ética para Engenheiros da *National Society of Professional Engineers (NSPE)* e do Código de Engenharia de Software da *ACM/IEEE-CS*, de forma a orientar o estudo e a atuar com responsabilidade, tanto em relação aos dados como às pessoas afetadas pela solução.

Tendo em conta que os dados a serem utilizados podem **conter informações confidenciais**, foi avaliada a possibilidade de os anonimizar e, caso não seja satisfatório para as partes

interessadas, será garantido que apenas os resultados agregados sejam apresentados, **evitando quaisquer riscos de exposição de dados confidenciais**. Para além disso, não foram identificados outros riscos éticos relevantes no projeto.

Para além dos códigos acima mencionados, foi também seguido o Código de Boas Práticas e de Conduta do Instituto Politécnico do Porto (IPP).

Quanto às competências necessárias, o autor é também um dos muitos membros de equipa de suporte que lidam com o tipo de problema que este projeto aborda, estando também a aprofundar os conceitos no mestrado que originou esta investigação. Essa combinação de experiência na área e aprendizagem académica ajuda a assegurar que o trabalho é feito com rigor, ética e atenção às melhores práticas profissionais.

1.6 Estrutura do Documento

No Final!

Capítulo 2

Estado da Arte

Este capítulo apresenta o estado da arte sobre o tema em estudo. Para esse efeito, é descrita a metodologia de investigação adotada para analisar a utilização de modelos de linguagem de grande dimensão no apoio à análise e resolução de incidentes em contextos de operações de TI. De seguida, são apresentados os principais artigos obtidos a partir da revisão da literatura, bem como uma discussão dos aspetos comuns e divergentes identificados nesses estudos. Esta análise permite consolidar uma base de conhecimento que serve de suporte à avaliação da viabilidade e à eventual adoção ou desenvolvimento de uma solução para o problema identificado.

2.1 Metodologia de Investigação

Optou-se por utilizar um método de pesquisa com base num estudo sistemático de mapeamento ou *Systematic Mapping Study (SMS)*, a fim de realizar a revisão de literatura. Primeiramente, foi definida uma pergunta de investigação, para estudar soluções já existentes no mercado. De seguida, com base na *Research Question (RQ)* definida e com o suporte da metodologia: População, Intervenção, Comparação, Outcome, Contexto e Tipo de estudo (PICOCT), foram identificados os elementos necessários para estruturar a pesquisa. Com a questão já enquadrada, prosseguiu-se para a definição das palavras-chave e dos limites de inclusão e exclusão. Por fim, para obter os artigos, foram utilizadas bases de dados de artigos científicos reconhecidas, tais como, a *ACM Digital Library* e a *IEEE Xplore*.

2.1.1 Pergunta(s) de Investigação

Com base nas dificuldades identificadas pelas equipas *DevOps* e *CorpOps* na análise e resolução de incidentes, surgiu a hipótese de recorrer a ferramentas de Inteligência Artificial (IA), como técnicas de Processamento de Linguagem Natural (PLN), para apoiar a compreensão e o tratamento destes registos. Desta forma, foi formulada a questão: **“Como é que as ferramentas de Large Language Models podem melhorar a interpretação e análise de registos de incidentes de TI?”**.

2.1.2 Metodologia PICOC(T)

A metodologia PICOCT é, geralmente, usada como guia para organizar e clarificar perguntas de investigação, ajudando a estruturar o problema de forma clara. Através desta abordagem, a pergunta é dividida em componentes simples, como a população em estudo, a solução

analisada, os resultados esperados e o contexto, tornando mais fácil de perceber o foco da investigação.

Existem várias variantes desta metodologia, como PICO, PCC ou POT, sendo a escolha da variante dependente do tipo de estudo e da área científica. Neste trabalho, a metodologia PICOCT foi utilizada para apoiar a formulação da pergunta de investigação e para identificar as palavras-chave usadas na pesquisa bibliográfica.

Com base na pergunta de investigação descrita anteriormente, foi possível realizar a decomposição pelos componentes da metodologia e a obtenção de palavras-chave para cada um desses componentes (Tabela 2.1).

Componente	Descrição	Inclusão/Exclusão	Palavras-Chave
P – População	Registos de incidentes	I — Ferramenta ServiceNow E — Estudos sobre gestão de alarmes	"incident management"; "incident analysis"; "incident resolution"; "incident interpretation"; "ticket analysis"; "ticket interpretation"; "ServiceNow"
I – Intervenção	Uso de LLMs para análise de incidentes	I — Técnicas conhecidas de LLMs E — - - -	"Large Language Model"; "LLM"; "Natural Language Processing"; "NLP"; "RAG"; "fine-tuning"
C – Comparação	_____	_____	_____
O – Outcome	Redução do MTTR, melhoria na priorização e diminuição de erros de análise	I — - - - E — Estudos não relacionados com incidentes	"incident"; "ticket"
C – Contexto	Ambientes DevOps/CorpOps	I — Estudos na área E — Estudos fora da área	"DevOps"; "CorpOps"; "IT"
T – Tipo de estudo	Pesquisa empírica ou com base em estudos	I — - - - E — Trabalho teórico ou especulativo	Exclui —> "theoretical"; "speculative"

Tabela 2.1: Metodologia PICOCT

2.1.3 Palavras-Chave

Foi definida uma string de pesquisa (Código 2.1) com o intuito de orientar a revisão bibliográfica. As palavras-chave utilizadas resultaram da aplicação da metodologia PICOCT, garantindo o alinhamento entre a pergunta de investigação e a pesquisa efetuada. Ao longo do processo, a pesquisa assumiu também um caráter exploratório e iterativo, permitindo o

ajuste dos termos sempre que necessário, de acordo com os resultados obtidos e com o foco do trabalho. Os termos foram formulados em inglês, de modo a ampliar o número e a relevância dos estudos encontrados.

```

1      ("incident management" OR "incident analysis" OR "incident
2      resolution" OR "incident interpretation" OR "ticket analysis" OR "
3      ticket interpretation" OR "ServiceNow")
4      AND
5      ("Large Language Model" OR "LLM" OR "Natural Language Processing"
6      OR "NLP" OR "RAG" OR "fine-tuning")
7      AND
8      ("incident" OR "ticket")
9      AND
10     ("DevOps" OR "CorpOps" OR "IT")
11     NOT
12     ("theoretical" OR "speculative")

```

Código 2.1: Termos de Pesquisa

Os termos finais foram posteriormente aplicados com a finalidade de obter os artigos científicos utilizados na investigação.

Os repositórios de pesquisa selecionados, mencionados na Tabela 2.2, possibilitaram a consulta de artigos e procedimentos mais fiáveis, relacionados com a área de estudo.

Repositório	Acesso à plataforma (URL)
ACM Digital Library	https://dl.acm.org/
IEEE Xplore	https://ieeexplore.ieee.org/

Tabela 2.2: Repositórios de Pesquisa

2.1.4 Critérios de Inclusão e Exclusão

Os critérios de inclusão e exclusão adotados neste trabalho e definidos nas Tabelas 2.3 e 2.4 são adicionais ao já estipulados na metodologia PICOCT e tiveram como principal objetivo delimitar o âmbito da revisão da literatura e garantir a sua relevância para a questão de investigação. São filtros adicionais que não podem fazer parte dos termos de pesquisa mas podem, normalmente, ser configurados nas próprias configurações dos repositórios de pesquisa.

Devido ao elevado número de artigos foi definido no critério *CI1* que, dos procedimentos originários de conferências, apenas seriam considerados trabalhos resultantes da *International Conference on Software Engineering (ICSE)*, da *ACM International Conference on the Foundations of Software Engineering (FSE)* e a *Automated Software Engineering (ASE)*.

A *ICSE* é uma das principais conferências internacionais, focando-se em inovações e tendências da área. Já a *FSE*, também conhecida como *ESEC/FSE*, destaca-se pelo foco em métodos, ferramentas e técnicas para o desenvolvimento e manutenção de *software*. Por sua vez, a *ASE* centra-se na automação de processos de engenharia de *software*, e em particular nos estudos que envolvem o uso de técnicas de IA no apoio a atividades operacionais, como é o caso deste estudo.

Identificador	Critério de Inclusão
CI1	Artigos provenientes de conferências reconhecidas e relacionadas com o tema

Tabela 2.3: Critérios de Inclusão


Com o critério *CE1* procurou-se dar prioridade a trabalhos mais recentes, reduzindo a probabilidade de incluir tecnologias que já não são relevantes.

Identificador	Critério de Exclusão
CE1	Publicado antes de janeiro de 2020
CE2	Artigos que não contenham resumo ou <i>abstract</i>
CE3	Artigos duplicados ou com conteúdos redundantes

Tabela 2.4: Critérios de Exclusão

2.1.5 PRISMA

Para organizar a revisão de literatura, recorreu-se ao método *Preferred Reporting Items for Systematic reviews and Meta-Analyses (PRISMA)*, que ajuda a tornar o processo de seleção de estudos **mais claro e transparente**. Com base nos artigos obtidos nos repositórios de pesquisa, e filtrando esses resultados pelos critérios de inclusão e exclusão, obtivemos os artigos que foram usados como base para esta investigação.

Figura 2.1: Diagrama *PRISMA*

Como demonstrado na Figura 2.1, foram obtidos 145 artigos dos dois repositórios de pesquisa dos quais 2 eram duplicados. Após a identificação inicial, os artigos foram filtrados pelos critérios de exclusão, onde 76 dos mesmos foram descartados por terem sido publicados antes de janeiro de 2020. De seguida, procedeu-se à filtragem pelos critérios de inclusão, que removeu 31 artigos que não se enquadravam nas conferências seleccionadas. Por fim, 30 artigos foram excluídos, após leitura do *abstract*, por não se enquadrarem no tema. Sobraram, dessa foram, 6 artigos para analisar na revisão de literatura.

2.2 Revisão de Literatura

Nesta secção, é demonstrada a análise dos resultados obtidos pela metodologia *PRISMA*, abordando os temas por categorias relevantes a esta investigação.

2.2.1 Análise de Causa Raiz e Correlação de Incidentes

As abordagens atuais para identificar as causas dos incidentes são, ainda, muito reativas e manuais, sendo que toda a investigação da origem do problema depende, quase exclusivamente, da experiência dos *OCEs* e da consulta da documentação técnica e registros das aplicações. Enquanto funcional, para ambientes controlados, estas abordagens tendem a apresentar limitações quando aplicadas a sistemas de grande escala.

Em paralelo, nos ambientes de grande escala, um único problema pode propagar-se por vários serviços e originar múltiplas ocorrências aparentemente independentes, fenômeno já identificado em sistemas reais de gestão de incidentes (Yujun Chen et al. 2020). Também afirmado por Yiru Chen et al. (2024), em sistemas de grande escala, uma única falha pode acionar vários alertas, uma vez que os serviços são altamente interligados e dependem uns dos outros. Consequentemente, é gerado um grande volume de alertas e incidentes em pouco tempo, o que dificulta a identificação dos alertas pertencentes à mesma falha para análise da causa raiz. Esta recorrência e repetição de incidentes está, assim, ligada ao aumento o tempo despendido na procura da causa e do melhor processo de mitigação e conduz, frequentemente, a diagnósticos redundantes ou demorados.

Torna-se importante identificar correlações entre incidentes que, à primeira vista, pareçam diferentes. Esta ligação entre ocorrências pode ter a mesma origem, os mesmos sintomas ou até descrições semelhantes. Trabalhos mais recentes mostram que a identificação de relações entre incidentes ou alertas relacionados é fundamental para apoiar atividades como a análise de causa raiz e a mitigação eficiente (J. Jiang et al. 2020; Roy et al. 2024).

Nos últimos anos, foi evidente o aumento da ênfase na reutilização do histórico de incidentes e na identificação dos padrões recorrentes entre eles. Estudos como J. Jiang et al. (2020) mostraram que a maioria dos incidentes acontecem de forma repetida ao longo do tempo e, muitas vezes, são mitigados utilizando o mesmo procedimento. Este trabalho apresenta o conceito de recomendação automática por meio de *Troubleshooting Guide (TSG)s*, demonstrando que a avaliação de incidentes anteriores pode ajudar eficientemente o processo de solução, diminuindo o esforço cognitivo das equipas de operações. De acordo com o mesmo estudo, apenas 27.2% dos incidentes tinham *TSGs* associados, revelando falta de documentação e, principalmente, que em maioria dos incidentes, os membros da equipa de suporte têm necessidade de investigar a fundo a causa das ocorrências. De notar ainda que, o artigo afirma que, 36.2% dos incidentes ocorreram pelo menos 2 vezes, podendo levar à reutilização dos métodos de mitigação.

Neste sentido, abordagens baseadas em aprendizagem automática e, mais recentemente, em modelos de linguagem de grande escala, têm vindo a ser exploradas para consolidar informação dispersa e apoiar a tomada de decisão durante incidentes complexos (Goel et al. 2024; Y. Jiang et al. 2024), reforçando a importância da correlação de *tickets* como etapa central na gestão operacional moderna.

2.2.2 Sugestões de Mitigação e Uso de Incidentes Anteriores

A maioria dos incidentes que surgem não são totalmente novos, mas sim recorrências de situações já observadas no passado. Ainda assim, identificar rapidamente estes casos de semelhança e as respetivas ações de mitigação continua a ser um desafio para os membros das equipas de suporte. O trabalho de J. Jiang et al. (2020) mostra, uma vez mais, que apenas de 27.2% dos incidentes possuem um guia de mitigação associado e que os *OCEs* despendem 36.3% do tempo total de mitigação apenas à procura do *TSG* correto. No mesmo

estudo, a abordagem proposta foi capaz de recomendar o guia mais adequado como primeira sugestão em 80.3% dos casos, confirmando, assim, o impacto direto do reaproveitamento de conhecimento histórico na redução do tempo de resposta.

Trabalhos mais recentes, exploram o uso de modelos de linguagem de grande escala para automatizar este processo de investigação de uma forma mais flexível. O estudo de Roy et al. (2024) demonstra que agentes baseados em *Large Language Model (LLM)* conseguem gerar sugestões de mitigação quando combinam descrições de incidentes com informação histórica e dados adicionais, como métricas e registos das aplicações, o que faz melhorar a qualidade das sugestões. De igual modo, o artigo de Goel et al. (2024) evidencia que a inclusão de contexto proveniente de diferentes fases do ciclo de vida do software melhora o desempenho dos modelos na geração de recomendações, quando comparados com abordagens que utilizam apenas uma fonte de informação.

Estes resultados, indicam que a análise de incidentes anteriores, quando suportada por fontes de informação adicionais, pode reduzir a carga cognitiva dos membros de suporte e tornar o processo de mitigação mais rápido, mais consistente e mais independentemente do nível de experiência do elemento de prevenção.

2.2.3 Apoio à Contextualização de Incidentes com LLMs

Para além dos temas abordados anteriormente, existe ainda um desafio inicial que os membros das equipas de suporte têm de superar. Antes de atuar sobre um incidente, seja por análise própria, por sugestões de mitigação ou até *TSGs*, os *OCEs* devem perceber o incidente em si, analisando as informações que são dadas de forma automática ou, quando criados manualmente, pelos clientes. Essas informações são muitas vezes pouco estruturadas e ambíguas.

Esta falta de contexto na fase inicial, impele os *OCEs* a iniciar uma investigação com base em informação limitada, o que faz com que os elementos de prevenção realizem várias tentativas para entender o impacto real do incidente e os serviços que são afetados. Em equipas com aplicações de grande escala, onde múltiplos incidentes podem ocorrer em simultâneo, uma primeira análise incompleta do incidente pode contribuir para atrasos na resposta e aumentar a pressão sobre os *OCEs*.

Desta forma, resolver incidentes torna-se num processo dependente da experiência dos membros das equipas de suporte, o que realça a necessidade da exploração de diferentes fontes de informação, como a análise de incidentes anteriores, métricas ou registos de eventos dos sistemas. Como demonstrado por Roy et al. (2024), agentes baseados em *LLMs* conseguem integrar várias fontes de dados durante a investigação, o que permite uma compreensão mais rápida do problema à medida que nova informação é incorporada.

Goel et al. (2024) mostra ainda que, incluir contexto adicional proveniente de diferentes fases do ciclo de vida do software, pode melhorar a capacidade dos *LLMs* em apoiar tarefas de análise e investigação. Este enriquecimento contextual, contribui para reduzir a incerteza inicial associada aos incidentes e orientar os *OCEs* de forma mais eficaz no primeiro contacto com os *tickets*. Adicionalmente, Y. Jiang et al. (2024) também apontam que os *LLMs* podem facilitar o acesso à informação operacional relevante, tornando tarefas que exigiam conhecimento específico sobre ferramentas e linguagens internas em tarefas automatizadas.

Em suma, a consolidação de informação histórica e contextual dos incidentes, apoiada por modelos de linguagem de grande escala e fontes de informação adicionais, desempenha um papel fundamental na redução da incerteza associada à investigação inicial de incidentes.

2.3 Conclusão

Com este capítulo, foi possível verificar, com base nos trabalhos analisados, que a gestão de incidentes em sistemas de grande escala é, ainda, muito afetada pela fragmentação da informação relacionada com as falhas que causam os incidentes, pela recorrência e duplicação de *tickets* em curtos intervalos de tempo e pela dependência da experiência dos *OCEs*. Assim, a literatura, mostrou que o uso de IA, como *LLMs* ou *Graph Neural Networks* (*GNNs*), facilita a contextualização inicial dos incidentes aos membros da equipa de suporte e ajuda na mitigação das falhas ao fornecer detalhes e sugestões de resolução com base em registos de incidentes anteriores.

Em síntese, e respondendo à pergunta inicial "Como é que as ferramentas de *Large Language Models* podem melhorar a interpretação e análise de registos de incidentes de TI?", é possível afirmar que estes Modelos de Linguagem de Grande Escala têm um papel importante no apoio da compreensão inicial, na análise e na procura de formas de mitigar os incidentes. São, assim, um apoio ao desenrolar do trabalho dos membros das equipas de prevenção.

No entanto, a análise crítica da literatura, mostrou que os estudos efetuados foram realizados com conjuntos de dados (*datasets*) estáticos e abordam apenas fases específicas do ciclo de vida de um incidente. Assim, o desenvolvimento de uma nova solução, que agrega várias fases deste ciclo e use um conjunto de dados dinâmicos, pode acarretar riscos ainda não identificados por estudos já realizados.

No capítulo 3, será discutido o futuro desta investigação, apresentando uma proposta de implementação capaz de alcançar os objetivos propostos no capítulo 1.

Capítulo 3

Futuros Desenvolvimentos

Texto introdução

3.1 Metodologia Proposta

Após a revisão da literatura, realizada no capítulo 2, conseguimos chegar à conclusão que as ferramentas de *LLM* quando utilizadas para correlação de incidentes, análise do histórico de *tickets* e sugestões de mitigação, podem ajudar os membros das equipas de suporte a compreender melhor os incidentes e resolvê-los de uma forma mais eficaz e eficiente.

Assim, pretendemos conceber uma solução que, através de *LLMs*, seja capaz de apoiar os *OCEs* na interpretação, análise e mitigação dos incidentes. Esta solução será baseada, numa fase inicial, pela ligação entre o incidente a resolver e os registos anteriores, aumentando a informação do incidente atual numa linguagem perceptível para qualquer membro da equipa de suporte, com mais ou menos experiência, e em qualquer contexto de trabalho e pressão. Em seguida, com a correlação de incidentes funcional, pretendemos gerar para o utilizador sugestões de mitigação que permitam uma rápida ação para resolver, temporariamente ou definitivamente, o problema, diminuindo o TMR.

Por fim, com uma ferramenta sólida para ajudar os *OCEs* na interpretação e mitigação de incidentes, propomos realizar a ligação com ferramentas externas de registos de eventos dos sistemas, ferramentas essas já usadas usualmente na análise manual dos membros das equipas de suporte. Dessa forma, pretendemos, reduzir o tempo gasto a analisar o incidente, diminuindo, uma vez mais, o tempo médio de resposta.

3.2 Desenho da Solução

Como referido anteriormente, o objetivo da solução passa desenvolver um serviço capaz de integrar com diversos serviços externos como:

- **Serviço de incidentes:** apresenta-se como sendo a base da solução, é a partir deste serviço que retiramos a informação do incidente a ser analisado e do histórico de incidentes para realizar a correlação;
- **Motor LLM:** outro elemento que devemos considerar como base da solução visto que, será responsável por fazer a ligação entre incidentes, a sumarização em linguagem natural e por recolher as sugestões de mitigação e as priorizar;
- **Serviço de logs:** como observado na revisão de literatura, informação adicional como registos de eventos dos serviços pode alavancar a performance do motor *LLM*, não

sendo uma componente obrigatória mas tornando-se numa ajuda para a análise dos *OCEs*.

Para além dos serviços funcionais descritos, a solução proposta deve ainda ser exposta através de uma interface de acesso controlada e escalável. Desta forma, propomos a utilização de um *API Gateway* (Gateway de API) para agir como uma porta de entrada do serviço, controlando autorizações e acessos, e gerir o tráfego de pedidos feitos à Interface de Programação de Aplicações (*API*). Em paralelo, apresentamos a necessidade de um *Load Balancer* (balanceador de carga) que ajuda a distribuir tráfego entre múltiplas instâncias do serviço, assegurando maior disponibilidade e tolerância a falhas.

Adicionalmente, é sugerido o desenvolvimento de uma aplicação *Web* que permita a visualização da informação gerada por parte dos *OCEs*, onde estes poderão consultar o resumo do incidente pretendido, *tickets* relacionados e sugestões de mitigação.




Figura 3.1: Diagrama de Implantação

Atendendo ao facto desta investigação se focar na análise de viabilidade de uma solução, optou-se por apresentar apenas o diagrama de implantação (Figura 3.1), que permite evidenciar as integrações principais, deixando o detalhe da arquitetura interna para uma fase mais avançada da investigação.

Na Figura, devo já indicar ferramentas como AWS, ServiceNow, Kibana ou é melhor ser genérico???

3.3 Fluxo de Funcionamento

Um processo de consulta de incidentes (Figura 3.2) tem início no serviço a ser desenvolvido, após a receção de um pedido de pesquisa de um incidente, é realizada a consulta do incidente na plataforma externa de gestão de incidentes, assim como o histórico de tickets anteriores.

De seguida, o serviço prepara a informação, combinando os dados do incidente atual com o histórico de incidentes anteriores, de forma a enriquecer o contexto disponível para análise e permitindo uma visão mais abrangente do problema. Já com os dados do incidente, é feita uma recolha dos eventos das aplicações num período próximo ao da falha e esses dados são adicionados à informação pré-processada do incidente.

Após esta etapa de enriquecimento e agregação de dados, o fluxo é direcionado para o motor de modelos de linguagem de grande escala, responsável por duas tarefas principais. De forma paralela, o *LLM* gera uma descrição do incidente em linguagem natural, tornando a informação técnica mais clara e acessível aos membros da equipa de suporte, e gera sugestões de mitigação priorizadas, com base no contexto do incidente, no histórico e nos eventos recolhidos, de forma a apoiar a tomada de decisão.

Por fim, os resultados produzidos pelo motor de *LLM* são novamente integrados no serviço central, que retorna ao utilizador a informação detalhada e contextualizada do incidente, incluindo a sumarização e as sugestões de mitigação.




Figura 3.2: Diagrama de Atividade

3.4 Pressupostos e Restrições

Projetos de soluções na área de TI, apresentam sempre riscos suscetíveis de acontecer durante a sua implementação ou até características que restringem o desenvolvimento da proposta. Por esse motivo, torna-se importante definir, logo de início, informações que possa limitar o progresso do projeto e criar planos alternativos que nos permitam, de forma mais controlada, lidar ou contornar estes problemas.

3.4.1 Pressupostos

Durante o planeamento do projeto, nem todas as informações podem ser assumidas como certas, sendo que muitos dos fatores não são controlados pelos membros das equipas de desenvolvimento. Os pressupostos são um conjunto de suposições que se assume que se vão realizar mas, que têm algum risco associado. Por norma, quando estas hipóteses são confirmadas, tornam-se restrições do projeto, porém, quando não é possível confirmar a sua premissa, acabam por se tornar em riscos do projeto. Dessa forma, devem ser criados planos alternativos para evitar que os riscos possam se tornar em barreiras ao desenvolvimento da solução. Os pressupostos e os planos de contingências foram identificados na Tabela 3.1.

Pressuposto	Plano Alternativo(s)
O conjunto de dados será entregue por uma das equipas da CTW num formato passível de utilização	Plano B - Obter um conjunto de dados sobre incidentes online de plataformas reconhecidas, como <i>Microsoft</i>
O motor LLM a utilizar será disponibilizado pela CTW de forma a não comprometer dados	Plano B - Desenvolver um <i>Small Language Model (SLM)</i> de raiz Plano C - Utilizar um LLM disponível com um <i>dataset</i> sem informação confidencial

Tabela 3.1: Pressupostos do Projeto

3.4.2 Restrições

As restrições do projeto são fatores que limitam as opções a tomar durante o desenvolvimento da solução. Estes fatores não são negociáveis e por isso a sua identificação precoce, é essencial para avaliar o futuro e a qualidade que proposta pode ter.

As restrições identificadas são:

1. Os dados presentes no *dataset* fornecido pela empresa terão de ser parcialmente/totalmente anonimizados.

Bibliografia

- Chen, Yiru et al. (2024). «Dynamic Graph Neural Networks-Based Alert Link Prediction for Online Service Systems». Em: *Proceedings of the 38th IEEE/ACM International Conference on Automated Software Engineering*. ASE '23. Echternach, Luxembourg: IEEE Press, pp. 79–90. isbn: 9798350329964. doi: 10.1109/ASE56229.2023.00177. url: <https://doi.org/10.1109/ASE56229.2023.00177>.
- Chen, Yujun et al. (2020). «Identifying linked incidents in large-scale online service systems». Em: *Proceedings of the 28th ACM Joint Meeting on European Software Engineering Conference and Symposium on the Foundations of Software Engineering*. ESEC/FSE 2020. event-place: Virtual Event, USA. New York, NY, USA: Association for Computing Machinery, pp. 304–314. isbn: 978-1-4503-7043-1. doi: 10.1145/3368089.3409768. url: <https://doi.org/10.1145/3368089.3409768>.
- Goel, Drishti et al. (2024). «X-Lifecycle Learning for Cloud Incident Management using LLMs». Em: *Companion Proceedings of the 32nd ACM International Conference on the Foundations of Software Engineering*. FSE 2024. event-place: Porto de Galinhas, Brazil. New York, NY, USA: Association for Computing Machinery, pp. 417–428. isbn: 979-8-4007-0658-5. doi: 10.1145/3663529.3663861. url: <https://doi.org/10.1145/3663529.3663861>.
- Jiang, Jiajun et al. (2020). «How to mitigate the incident? an effective troubleshooting guide recommendation technique for online service systems». Em: *Proceedings of the 28th ACM Joint Meeting on European Software Engineering Conference and Symposium on the Foundations of Software Engineering*. ESEC/FSE 2020. event-place: Virtual Event, USA. New York, NY, USA: Association for Computing Machinery, pp. 1410–1420. isbn: 978-1-4503-7043-1. doi: 10.1145/3368089.3417054. url: <https://doi.org/10.1145/3368089.3417054>.
- Jiang, Yuxuan et al. (2024). «Xpert: Empowering Incident Management with Query Recommendations via Large Language Models». Em: *Proceedings of the IEEE/ACM 46th International Conference on Software Engineering*. ICSE '24. event-place: Lisbon, Portugal. New York, NY, USA: Association for Computing Machinery. isbn: 979-8-4007-0217-4. doi: 10.1145/3597503.3639081. url: <https://doi.org/10.1145/3597503.3639081>.
- Roy, Devjeet et al. (2024). «Exploring LLM-Based Agents for Root Cause Analysis». Em: *Companion Proceedings of the 32nd ACM International Conference on the Foundations of Software Engineering*. FSE 2024. event-place: Porto de Galinhas, Brazil. New York, NY, USA: Association for Computing Machinery, pp. 208–219. isbn: 979-8-4007-0658-5. doi: 10.1145/3663529.3663841. url: <https://doi.org/10.1145/3663529.3663841>.